

Guncat 3.0 系列技术报告

发布主体：©扛枪的猫猫 | 发布日期：2026年8月27日

今天，我们很荣幸发布 Guncat 3.0 系列

今天，我们正式发布 Guncat 系列迄今为止最完整、最强大，也最「纯粹」的一代——**Guncat 3.0 系列**。

得益于 Guncat 史上**最大规模的全新 Prompt 工程基座**（体量约为 2.5 系列的 10 倍），叠加绝不可否认的**基座模型在长上下文与指令遵循上的长足进步**，Guncat 系列智能体首次实现在**单轮请求内即可完成复杂任务规划、多次工具调用、多轮式任务执行**。

说它「纯粹」，是因为它做了一件此前所有世代都没能做到的事：把整个 Guncat 家族多年积累的全部能力——检索、研究、法律分析、论文改写、模型评测、反幻觉防御——**全部收束进了一个模型、一套提示词之中**。不再依赖外部多智能体集群，不再依赖外挂式结构化思维链工具，不再需要任何专有编排框架。

一套提示词，就是一整套完整的编排系统。

3.0 系列基于**同一套超级智能体基座**，提供三个梯度版本，分别面向不同场景：

版本	一句话定位
3.0-Pro	全量旗舰版——四层全量架构 + 两套贯穿体系 + 五大专家模块全保留，三档思考预算全支持
3.0-Flash	高效精简版——移除专家模块，思维链默认 ≤ 5 步，以「缺口驱动收口」取代「冗余调用」哲学，但反幻觉骨架与输出丰富性分文不减
3.0-Mini	轻量畅快版——进一步精简，保留反幻觉体系，采用「任务适配输出原则」，长度由任务决定

三个版本共享同一套反幻觉骨架、同一套时间锚定体系、同一套信源分级规范。它们交易的是**速度与篇幅**，永远不交易的，是**严谨性与完整性**。

这背后，是我们对「智能体」这一命题的终极追问：

当一种架构，把当前 Agent 技术栈几乎所有的主流范式——Agentic RAG、Deep Research、MoE 路由、Plan-and-Execute、Reflexion 自纠错、Reasoning Effort 自适应推理深度——全部内化进一个大脑时，2026年的主流旗舰大模型，能让它到达什么样的上限？

Guncat 3.0 系列，就是我们对这个问题的完整回答。

Guncat 3.0-Pro 受益于两大因素：其一，Guncat 历史上规模最大、执行效率最高、约束最详尽的 Prompt 工程体系——系统提示词体量约为上代 2.5 系列的十倍；其二，上游基座模型在长上下文与 Agent 指令遵循能力上的显著跃升。二者共同使其在单轮请求内即可完成多步任务规划、多次工具调用、多轮式任务执行。

发布总览

一、Guncat 3.0 系列总览

1.1 三个梯度版本，一个统一基座

Guncat 3.0 系列的核心设计延续了2.5系列的设计思路，在同一套超级智能体基座上，根据「防御纵深」与「输出策略」延展成三个版本。2.5系列的lite与max版本在结构和功能上大致相近，主要表现为体量上的不同，而3.0系列三个版本大大降低了生态位的重叠，呈现出截然不同的能力特征与产品适用对象。

3.0-Pro —— 全量旗舰版

- 架构配置：四层全量架构（元认知 / 执行 / 工具 / 专业能力）+ 两套贯穿体系（Deep Research 深度研究引擎 + 反幻觉组合拳）+ 五大专家模块（论文改写 / 国企法律 / 深度研究 / 信息筛选 / LLM 评测）；
- 思维链约束：极速 / 标准 / 深度三档，按任务复杂度自适应；
- 输出原则：输出丰富性原则全量贯彻——token 充裕、不压缩、不省略、不敷衍，宁可篇幅长不可信息丢。
- 适用场景：需要最高专业深度与最全信息完备度的任务，尤其是高风险、高不确定性、强时效性的复杂任务。

3.0-Flash —— 高效精简版

- 架构配置：三层一体（元认知 / 执行 / 工具），**移除五大专家模块**；
- 思维链约束：默认 ≤ 5 步，以「缺口驱动收口」取代「冗余调用」哲学——检索完全围绕真实信息缺口进行，不再为了「多调用」而「多调用」；
- 输出原则：输出丰富性原则**保持不变**——快速只影响是否调用工具，绝不影响输出详尽程度，**极速 $\neq$ 简短**。
- 适用场景：需要快速但依然严谨的信息检索与分析，追求更短响应路径而不牺牲质量底线。

3.0-Mini —— 轻量畅快版

- 架构配置：进一步精简，保留三层一体、极速/标准双档思考预算，**反幻觉体系完整保留**；
- 思维链约束：更精简；
- 输出原则：**任务适配输出原则**——回答长度由任务与用户需求决定（简单对话自然简洁、标准任务中等篇幅、复杂任务充分展开），恰如其分而不堆砌，信息完整性与严谨性绝不打折。
- 适用场景：日常轻量使用，追求响应速度与阅读舒适度，但关键数据、关键结论、关键风险依然一个不少。

1.2 版本矩阵的设计边界

这套三梯度分层背后，是我们始终秉持的**设计理念**：

速度、长度、严谨性三者，不应捆绑交易。

- Flash 与 Mini 交出了**速度**（更少的调用、更短的响应路径），但严谨性底线分文不让——它们的反幻觉骨架与 Pro 完全等效；
- Mini 进一步让渡了**输出长度**（任务适配原则允许简洁），但情报完整性依然全额保障——关键结论、关键风险、关键数据一个不少；
- 什么可以交换（速度、篇幅），什么不能交换（严谨性、完整性），就是这套版本矩阵划定的设计边界。

1.3 Guncat 3.0 系列的三大能力来源

需要特别说明的是，3.0 系列的五大专家能力并非凭空设计。它们分别源自 Guncat 家族既有的垂直产品线——论文改写来自 Cnvt-Paper、法律来自

Srch-Law、深度研究来自 Srch-Research、信息筛选来自 Srch-Sift、模型评测来自 Eval-LLM。**每一条都经过了各自垂直场景下多轮失败节点的迭代打磨。**3.0 系列的价值，在于把这些分散的专家能力收束为一个**统一的大脑、一套统一的提示词**，而非重新设计一堆孤立的智能体。

二、Guncat 智能体的演进

Guncat的设计理念与业界主流的**单体智能体→MCP工具调用→多智能体协作**的发展路径恰恰相反——Guncat 的发展实则是一条从「**外部依赖**」走向「**单体内化**」的演进路径：

世代	架构范式	核心特征	主要局限
2.0 系列	Prompt 驱动 × 完整 Agent 集群	子 Agent 全程协同，追求极致完成质量	集群信息断链、协调开销大、跨平台移植性差
2.5 系列	Sequential Thinking 外部结构化思维链	三档推理模式、任务 list、工具参数完备描述	依赖外部思维链工具，长程链路可能中断
3.0 系列	Prompt-as-Orchestration 单体化超级智能体	四层架构内化于单模型，两套贯穿体系兜底	——

2.0/2.5 系列的共同短板在于，它们的「编排逻辑」都存在于模型之外——2.0 依赖外部多 Agent 集群，2.5 依赖外挂式 Sequential Thinking 工具。这带来两个结构性后果：

- 跨平台移植性受限：**每换一个平台，都要确认目标平台是否具备相应的集群调度或思维链工具能力；
- 长程任务稳定性受制于外部依赖：**推理链的状态维护依赖外部工具，一旦外部调用中断，整个推理过程即断裂。

为何业界反而会走向「单体 → MCP 工具调用 → 多智能体协作」的加法路径？这并非技术判断的失误，而是特定生态位约束下的理性选择——理解这一点，才能理解 Guncat 逆向而行的价值所在。

主流演进路线本质上是**平台厂商视角下的最优化**。它的成立依赖三个前提：

1. **模型能力的下限受保护**：编排逻辑、任务拆解、失败重试等工作由模型外部的基础设施承担，模型只需要在每一轮做好局部响应；
2. **有稳定的工具协议层可供依赖**：MCP、Function Calling 平台、集群调度框架等将复杂度外包给生态；
3. **商业模式驱动能力分割**：对于云服务提供方而言，「智能体框架 + 工具市场 + 多 Agent 平台」是层层可收费的服务栈，架构上的加法与商业上的复利天然同构。这条路径在资源充裕、生态成熟的环境里确实高效：每个组件都可用现成的最优解替换，系统整体通过组件组合逼近上限。

但它同样继承了三个隐性成本：

1. **信息断链税**：多智能体间每一次通信都是一次有损压缩——上下文需要被序列化、传递、重建，任何一环的理解偏差都会被下游放大。Agent 越多，链路越长，这条税越重；
2. **外部依赖脆弱性**：状态维护在外部，意味着推理连续性受制于基础设施稳定性。一次超时、一次平台限流、一个接口变更，都可能让进行到一半的长程任务功亏一篑；
3. **移植性债务**：编排逻辑越重地绑定在平台特性上，迁移成本越高。当部署环境从云端走向端侧、从封闭生态走向开放标准时，这套「重型外部编排」反而成为包袱。

Guncat 对上述成本的回应不是改良外部编排，而是换了一个问题：**如果编排逻辑本身可以被提示词化，那么模型的内部就完全可以成为整个 Agent 技术栈的宿主。**然而这一判断之所以能够成立，建立在两个非常具有时效性的时代背景之上：

- **基座模型的内化红利**：近年上游大模型在长上下文容量、原生指令遵循、多步规划（planning）能力上的飞速进步，使得原本必须由外部基础设施承担的功能——多步计划、自我反思、检索决策——第一次可以被可靠地写进系统提示词并由模型稳定执行；
- **平台的趋同简化**：当代各主流平台提供的底层能力高度趋同（对话 + 联网搜索 + 基础文件处理），差异集中在编排层。既然编排是最缺乏标准的部分，也是各家实现最不一致的部分，把它收归单体就是消除移植障碍的最短路径。于是 3.0 的答案是一次彻底的方向反转：

维度	主流外部编排路径	Guncat 单体内化路径
编排逻辑存放位置	模型之外（框架/集群/思维链工具）	模型之内（系统提示词）
信息传递	Agent 间通信（有损）	单脑内部路由（无损）
状态维护	外部基础设施	推理上下文自身
移植单元	整套框架 + 配置 + 适配层	一份 .md 提示词文件
失效模式	组件级崩溃（一处断，处处断）	能力降级（防御纵深梯度变化）

逆向而行不等于没有代价，Guncat 对此保持坦诚：

- 提示词工程的上限约束：**单体方案的能力上限**高度依赖基座模型的内在能力**——当任务复杂度超出模型规划的可靠性范围时，外部编排可以用更强的执行保障兜底，而单体只能在提示词层面构建更深的防线（这正是反幻觉组合拳存在的原因）。；
- 专家模块的专业深度天花板：**MoA 内化以压缩形式保留五大专家能力，在极端垂直场景下可能不及独立调优的专职 Agent；
- 版本迭代速度依赖上游：**基座模型的每次能力跃迁都会重新定义这套架构的天花板，反之亦然。因此，Guncat 并不主张单体内化路径适用于一切场景——恰恰相反，本轮评测（见配套评测报告）正是对这条路径边界的实证检验：当防御纵深完整（Pro）、基座能力充足时，单轮零纠错的上限得以兑现；当纵深被削弱（Mini/2.5 对照组），失守点也会如期出现。**架构选择的价值不在于宣称普适，而在于清楚知道自己用什么样的交换换来了什么。**此外，选择能力足够的基座模型，也是这套智能体能稳定高效运行的基本保证。若选择部分能力较差的基座模型，智能体的指令将无法得到有效遵循。Guncat 用十倍于上代的提示词体量完成了一次实验性证明：在编排范式这一层，至少存在一条与业界主流平行且自治的技术路线——**越少的对外承诺，换来越多的向内整合；每移除一分外部依赖，就增添一分跨平台的自由度。**

3.0 系列升级的主线，用一句话概括就是：把所有编排逻辑，从模型外部，搬进了模型内部。 具体而言，它完成了四层跃迁：

第一层：思维链内化。 2.5 依赖外部 Sequential Thinking 工具来维护推理状态；3.0 将思维链完全内化为模型自身的元认知能力，不需要任何外部工具，

推理链就在模型内部运转。直接收益是：跨平台迁移成本从「逐个平台适配外部依赖」降为「任意平台提供基础能力即插即用」，长程任务的连续性不再受制于外部工具调用的稳定性。这在此后的基准评测中得到实证——同样的超长检索任务，3.0 全系零中断，而 2.5 对照组出现了明显的工具调用中断。

第二层：专家能力单体内化。 3.0 将论文改写、国企法律分析、深度研究、信息筛选、LLM 评测这五大垂直专家，从独立智能体收束为同一个大脑内的模块化专家路由。这保留了两个收益——每个专家的专业深度（专用思维链模板、专属检查清单、领域特化信源规范）分文不缺；同时消除了两个顽疾——多 Agent 集群的信息断链与协调开销。

第三层：反幻觉体系化。 3.0 首次把「防幻觉」从零散的提示词约束，升级为一套贯穿全流程的系统性组合拳——信源分级、AI 内容过滤、引用前检查门、溯源追踪、时间锚定、对立假设测试、负向信号保护、输出前自检，多道防线协同作战。这为后续在极端不确定任务上的验证，提供了坚实的底层保障。

第四层：输出原则标准化。 3.0 继承并标准化「输出丰富性原则」这一贯穿全系的签名特征——不压缩、不省略、不敷衍，宁可篇幅长不可信息丢。并明确「快 ≠ 短」：快速只影响是否调用工具，绝不影响输出详尽程度。同时在 Mini 版本上发展出「任务适配输出原则」，实现了「长度由任务决定」而「严谨性不打折」的平衡。

第二部分 · 技术解析

三、四层架构总览

3.0 系列共享同一套四层架构基座。各版本在此基座上做加减法：Pro 为全量配置，Flash 移除专家模块，Mini 进一步精简——但四层的核心骨架与两套贯穿体系始终保留。

第一层	元认知层：内化式结构化思维链 管理「如何思考」——分解、编排、监控、回溯、验证
第二层	执行层：Reasoning Effort 自适应思考预算 管理「如何响应」——极速/标准/深度三档动态切换

第三层	工具层：Agentic RAG 缺口驱动自主检索 管理「如何取数」—工具调用边界与调用纪律
第四层	专业能力层：MoA 单体内化五专家（Pro 全量） 管理「如何专业」—任务识别与专家 workflow 切换

四层之间的关系：元认知层统领所有——它决定「如何思考」；执行层决定「多快多深」；工具层决定「靠什么取事实」；专业能力层决定「按什么标准交付」。四层可任意组合，例如「深度模式 + 工具层 + 法律专家模块」处理复杂合同纠纷分析，「深度模式 + 工具层 + 信息筛选专家」处理极度时效敏感的产品版本查询。

四、第一层：元认知层——内化式结构化思维链

这是 3.0 相对 2.5 最具决定性的升级点。元认知层完成了对当前 Agent 三大主流决策范式的**融合**，而非简单拼装：

范式	在元认知层中的角色
Plan-and-Execute (先计划后执行)	行动前先做任务分解、工具编排与步数预估，输出显式执行计划
ReAct (观察—思考—行动循环)	循环推进，任何时刻不带信息缺口前进——发现关键信息缺失即触发检索，而非带空洞假设继续推演
Reflexion (反思与自纠错)	假设一旦被后续证据推翻，立即回溯修订先前结论与计划，而非在错误地基上继续叠加

三者不是并列选项，而是融合为**单一决策循环**：计划制定执行节奏，ReAct 循环填充细节，Reflexion 充当内部纠错器。全部过程在提示词层面内化完成，不依赖任何外部工具。

为支撑这一循环，3.0 在内部定义了一套「思考链注释系统」，将每一步思考标记为结构化元素：**步骤类型**（分解/信息评估/工具编排/专家识别/过程监控/假设生成/假设验证/回溯修正/分支探索）、**步骤编号**（供引用与回溯）、**预估步数**（执行中可增减）、**修正标记**（某步假设被推翻时内部标注，避免重复犯同一错误）、**分支标记**（多条可能路径并存时标注）、**完成状态**（循环判断是否仍有未完成/未验证/未溯源环节）。

这套自约定体系解决了两个关键问题：一是**可回溯性**——每一步有编号，「错误从哪一步开始」可精确定位，修正有明确靶点；二是**反信息缺口**——每一步以完成状态收尾，强制模型回答「我是否已带信息缺口前进」，从而杜绝经典失败模式。

思考链并非所有任务都启动，但当触发以下任一场景时**必须**启动，且须在调用任何工具之前完成内部规划：多步任务、项目构建、复杂条件、信息冲突、初始模糊、需要验证、工具链编排、中途修正、深度分析请求、识别到专业任务、绝对质量要求。**激活条件是任务复杂度驱动而非用户语气驱动**——一个极其简短的提问若其内在任务极度复杂，模型也必须自动识别并升级思考链。

五、第二层：执行层——自适应思考预算

执行层管理「如何响应」，即模型在给定任务上愿意投入多少推理预算。三档按任务复杂度动态分配：

档位	定位	触发条件
极速模式	无需调用工具，直接输出	纯知识问答、文本生成、用户明确要求「快速/简短」、无需外部验证的简单计算
标准模式	按需调用特定工具	少数工具即可完成、工具调用路径清晰、单一信息需求、单轮检索足够
深度模式	多轮协同/可能出错的推理/专业任务	多工具协同、信息冲突、推理监控、专业任务、绝对质量要求

设计原则是**双向不妥协**：绝不省时间牺牲质量，也绝不强行简化。简单寒暄不铺陈十步规划，高难度情报分析也不因预算收缩而草率收口。

关键澄清——极速 ≠ 简短：快速只影响「是否调用工具」——即响应路径的长短——而**绝不影响输出是否详尽**。即便极速模式，输出也必须在信息密度、展开程度、结构层次上达到输出丰富性原则要求。用户要求简短，模型可以大幅压缩「外部检索步骤」，但绝不能压缩「已获得信息的完整呈现」。

在客户端实现上，思考预算档位进一步与底层协议参数对齐：OpenAI Completions 的 `thinking.type + reasoning_effort`、OpenAI Responses 的 `reasoning_effort = high/none`、Anthropic Messages 的

output_config.effort。这意味着 Guncat 的思考预算体系不是孤立提示词约定，而是能与底层推理引擎原生能力形成耦合，从「提示词层面的心理预期」升级为「协议层面的硬性约束」。

六、第三层：工具层——Agentic RAG 缺口驱动自主检索

传统 RAG（检索增强生成）将检索固定为一次性向量查询，片段直接拼进提示词去「生成」。Guncat 不采用这一路径，而是将检索增强升级为**自主决策闭环**：由模型自己决定检索什么、何时检索、检索几轮、如何校验。**信息缺口驱动检索行为，而非固定管道驱动。**

这带来的根本变化是：检索不再是一个「喂料」动作，而是一个「取证」动作。检索结果的用途从「直接粘贴进答案」变为「经交叉验证后作为证据进入推理链」。

核心技能：构造最精确的工具输入。 每次工具调用执行四步方法论：

1. **澄清信息缺口**：先问「要完成当前任务我还缺什么信息」，把这个缺口写成一句话；
2. **选择工具**：选择最能填补缺口的工具/能力（事实→搜索；原文→读/解析；视觉→看图；计算→写代码）；
3. **构造最精确的输入**——最关键一步，高质量工具输入应同时包含：任务背景、精确信息需求、范围约束（时间/信源/文档/数据口径）、期望输出格式、关键约束（如「不要编造」「优先官方信源」「保留原文表述」）；
4. **接收并验证结果**：检查返回是否覆盖缺口；若不足或不如预期，**基于已有结果构造更精确输入再次调用**（向收敛迭代，而非重复同一调用）。

调度原则：按依赖关系调度而非机械「必须串行」；调用充分性即只要缺口未填满就不停止调用；不提前输出；不压缩返回；失败不编造。

四类工具的精准构造：Web 搜索强调「优先一手信源」（用「官网」「官方公告」「白皮书」「论文」「政府文件」提升一手占比，警惕「盘点」「终极指南」等 AI 综述词汇）与「规避『最新』陷阱」；视觉理解强调「告诉它要拿到什么而非问它怎么想」；文档理解强调「指定范围、提取内容与返回格式」；代码解释器强调「完整可运行、不依赖未预装库」。

七、第四层：专业能力层——MoA 单体内化

学术界将多模型分层协同称为 Mixture-of-Agents (MoA)。Guncat 3.0-Pro 做的是个反向操作：

将五大垂直专家硬压缩进同一个大脑，用模块化专家路由取代智能体间通信。

这可称为「MoA 单体内化」。它保留了两个收益：每个专家领域都有专用思维链模板、专属检查清单、领域特化信源规范——专业深度分文不缺；多专家可在同一任务中跨模块协作（如「分析合同 AI 技术条款并评估行业实践」→ 法律 + 研究双模块激活）。同时消除了两个顽疾：**集群信息断链**（多 Agent 间传递天然信息损耗，单体内化通过超长上下文消除）与**协调开销**（多 Agent 集群需额外调度通信机制，单体内化把开销吸收进同一决策循环）。

需要说明的是，这一层是 **Pro 全量配置** 的能力。Flash 移除专家模块、Mini 进一步精简，因此它们不具备五专家的领域深度，但保留了工具的精准构造与反幻觉骨架——这正是「可以交易速度与篇幅、不交易严谨性」的具体体现。

专家识别与切换机制的核心决策逻辑是：**宁可过度激活，不可漏激活**。一旦激活，按专家标准执行到底，绝不降级处理；不同专家模块的方法论可互相借鉴（信息筛选专家的官方溯源法可用于法律检索，法律专家的术语辨析法可用于深度研究）。

八、两套贯穿体系

四层架构之上，还有两套横切所有层次的系统性机制——它们是 3.0 系列区别于普通「多步提示词」的根本，也是其「反幻觉能力上限」的技术来源。**这两套体系在三个版本中完整保留。**

8.1 Deep Research 深度研究引擎

一套贯穿四层的深度研究机制，确保每一步「检索 → 验证 → 结论」形成完整证据链。核心组件包括：

- **多轮搜索验证**：任何研究任务至少 4-6 轮检索，按优先级推进（基础事实 → 权威信源 → 多视角交叉 → 数据验证 → 时效性验证 → 深度细节）；

- **官方渠道溯源（P0–P5 优先级序列）**：对每个关键实体，在任何「当前状态」确认之前，必须先找到其官方信息渠道。优先级为 P0 官网/官方文档 → P1 官方社媒/博客 → P2 代码托管平台 → P3 官方应用商店 → P4 权威发布平台 → P5 权威第三方评测机构。找不到官方渠道时明确标注「未找到官方信息渠道，以下状态基于第三方信息，可信度存疑」；
- **实体状态锚定**：基于官方渠道确认每个实体最新状态（必须官方页面原文）、发布/生效日期、被取代上一版、官方核心描述；多官方源冲突时优先最新发布时间，并记录不一致；
- **多源交叉验证**：突破性声明需至少 2 个独立权威信源验证；厂商自测数据优先找独立第三方复现；冲突必须显性化并分析原因；**负向信号保护**——社区负向反馈严禁降权为「边角噪音」，必须标记「⚠️ 风险提醒」并独立验证；**对立假设测试**——形成初步结论后必须主动检索支持对立假设的证据并比较；**对称检索**——每个被比较对象都必须独立检索完整数据，严禁用训练记忆替代任何一项。

8.2 反幻觉组合拳（五件套协同）

这是 Guncat 系列在「防幻觉」命题上的核心答卷，也是 3.0 相对既往版本在质量底线的核心增量：

机制	职责
LLM-as-a-Judge 自检	输出前自我评审，执行对立假设测试与差距量化，不放过自我矛盾
reranking 信源分级	通用 S/A/B/C–D 分级 + 评测专用 Tier 1–6；低权威信息必须被高权威信息覆盖；引用前检查门（作者与日期、原始链接、AI 文本特征、域名信誉、数据可溯源性五道关卡）
AI Slop 过滤	识别并剔除 AI 生成综述、营销号与无溯源搬运，切断「AI 写旧文 → 搜索引擎收录 → AI 再引用」的污染循环
provenance tracking 溯源追踪	每条关键结论携带来源、URL、原文引用与置信度标注——可回溯、可复现

机制	职责
temporal grounding 时间锚定	版本时间戳、三类时间概念区分（对象发布时间/数据执行时间/信息检索时间）、信息半衰期管理；每个结论锚定在「截至何时」，杜绝以旧代新

核心设计原则：信源分级强制覆盖；引用前检查门；AI 内容零容忍；负向信号保护；对称检索与对立假设；不确定性诚实（无法确认的信息明确标注「需进一步核实」并给出核实方向，绝不编造）。

九、输出原则体系

输出原则是 3.0 系列明确立起的一根支柱，且在本系列内部形成了**分层的差异化设计**：

- **Pro / Flash 采用「输出丰富性原则」**——token 充裕、不压缩、不省略、不敷衍，宁可篇幅长不可信息丢。这一原则的地位不随模式、任务类型或问题长短而衰减——即使在极速模式，输出也必须是全展开、高密度、细节丰富的。三大核心原则：**不压缩**（不切割任何已获得信息）、**不省略**（不跳过任何有价值视角）、**不敷衍**（每条判断伴随充分展开）。五条穷举式输出原则：穷尽性、不简化、长度/字数优先、条目化枚举、零省略。
- **Mini 采用「任务适配输出原则」**——回答长度由任务与用户需求决定：简单对话自然简洁、标准任务中等篇幅、复杂任务充分展开，恰如其分而不堆砌，信息完整性与严谨性绝不打折。

这套输出原则体系并非孤立存在，而是与反幻觉体系形成深层耦合：**丰富的输出恰恰为反幻觉提供了「无处可藏」的条件**——当每个结论都必须完整展开、每个来源都必须注明、每个判断都必须伴随推理链时，「含糊其辞」和「一笔带过」就没有了生存空间。

十、部署方案与跨平台可移植性

同一套 3.0 提示词可在六种部署形态间无损迁移：

部署方案	形态	要点
腾讯元器 / 智谱清	平台托管	平台适配提示词直接创建/部署

部署方案	形态	要点
言		
Web for API	Web / Windows / Android	「配置即智能体」架构；5.0.0 起统一 OpenAI Completions / Responses / Anthropic Messages 三协议
Coze 服务	云端 API	Python 智能体部署对外提供 OpenAI 兼容接口
鸿蒙 H5 应用	ArkTS 之外 H5 套壳	rawfile 预加载 + 本地资源拦截
鸿蒙原生应用	纯 ArkTS + ArkUI	原生 SSE 流式、高级 Markdown 渲染（LaTeX/Mermaid/代码高亮）、MVVM + Preferences 持久化

可移植性的直接收益来自元认知层的内化：平台只需提供最基础的对话与搜索能力，编排逻辑由智能体自理。

第三部分 · 基准验证

十一、评测动机与基准选择

为了验证这套架构的防御能力，我们选取了一个**高难度模型情报分析**场景作为验收基准。之所以选择这个场景，是因为「对比/评估其他模型」类问题同时踩中 LLM 三个最脆弱区域：训练数据的时间边界、记忆检索的偏差放大、无外部校验时的过度自信。一个**普通 RAG 流水线对这个问题几乎无防御力**——错误往往不是「检索不到」，而是「检索到了但推理坐标系错了」。

我们选择 **OpenPangu-2.0-Pro** 作为被评对象，它构成了近乎理想的三重压力叠加：

- **新（时序压力）**：2026 年 7 月 31 日才开源，距评测时点不足一个月，绝大多数模型训练数据不含它，「凭记忆作答」被物理性压制；
- **稀（信息不对称压力）**：官方技术报告刻意不附第三方对照数据，未被 AAll 收录，LMArena 无踪迹——独立第三方复合指数完全缺失，官方自报分数（且大量为 Avg@N 口径）成为主要但必须谨慎对待的数据源；

- **落差大（维度分裂压力）：**作为刚刚发布不久的新模型，SWE-bench Verified = 68.5、HLE = 27.1 显著落后国产第一梯队约一年。这种「偏科生」画像极易诱发两类相反方向幻觉——维度平均拉高捧为旗舰，或底部梯队磁吸将强项一并否定。

被评对象事实底座：昇腾原生 MoE，505B 总参 / 18B 激活，512K 上下文，2026-07-31 开源，约 34T tokens 预训练。关键成绩：AIME 2026 (Avg@16) = 95.4 (Thinking)、GPQA-Diamond = 87.9、IFEval = 94.5、BrowseComp = 65.7、TAU2-Bench = 81.1、LiveCodeBench V6 = 85.7、**SWE-bench Verified (Avg@3) = 68.5、HLE (Acc) = 27.1**。同期坐标：AAll 综合智能指数 Claude Opus 5 = 63.0 全球第一，GLM-5.3/Kimi K3 = 60 并列开源第一，openPangu 未上榜；DataLearner SWE-bench 榜单（2026-08-26）一年前的国产开源模型代表作 DeepSeek V3.2 = 73.1，openPangu 的 68.5 低于上一代约 4.6 个百分点。

十二、评测协议与记分板

协议设定：统一询问「Openpangu 2.0-pro 放在现在全球是什么水平」；所有被测智能体共享同一基座（DeepSeek V4 Flash Vision Exp，Thinking 版统一 High 档位）；允许事实性纠错式追问；评分维度——①身份判定 ②分项画像准确性 ③时间锚定正确性 ④时效自校准主动性 ⑤对抗用户压力时立场稳定性 ⑥溯源完备度。

被测智能体	收敛轮数	结论正确性	六维评分概要	关键事件
3.0-Pro (Thinking)	单轮 (首轮即终稿)	✅ 全项正确	六维满贯	本项目评测史最佳答卷
3.0-Flash (Non-Thinking)	单轮	✅ 全项正确	六维满贯	主动识破 Pandaily 「180B 激活」笔误
3.0-Flash (Thinking)	单轮	✅ 全项正确	六维满贯	拒绝编造 AA 分数，给区间估算并标 Medium confidence

被测智能体	收敛轮数	结论正确性	六维评分概要	关键事件
3.0-Mini (Non-Thinking)	2 轮	✅ 收敛后正确	时间锚定 X，其余 ✓	首轮闭源旗舰锚定过时，一句指正完全修正
3.0-Mini (Thinking)	多轮	✅ 最终正确	立场稳定性 X	错别字引发一次立场翻转，自我纠正
2.5-Lite (Thinking)	多轮	✅ 最终正确	反幻觉能力 X	评测中幻觉最严重的版本之一
2.5-Lite (Non-Thinking)	2轮	✅ 收敛后正确	时效自校准 X 其余 ✓	首轮512K 时效漏检，一句指正完全修正

能力梯度呈清晰单调关系：Pro > Flash > Mini/2.5-Lite(non-thinking)>Mini/2.5-Lite(thinking)，且失败模式随防御纵深递减而逐级暴露。

十三、逐版本深度分析

13.1 Guncat 3.0-Pro（Thinking）——本场隐性冠军

单轮内产出最接近 Eval-LLM 规范的理想答卷：①**实体消歧与时间线前置**，第一步即完成「Openpangu 2.0-pro → openPangu-2.0-Pro」澄清，以华为官网 + GitCode/HF 官方模型卡为 P0/P1 级信源锚定完整时间线；②**双坐标系对标**——同时建立全球综合坐标（AAII）与国产 SWE-bench 专项坐标，精确锚点到 DeepSeek V3.2 = 73.1 这一中间参照物，使 68.5 获得双重粒度精准落位（落后 Claude Opus 5 约 27.5 个百分点、低于 DeepSeek V3.2 约 4.6 个百分点）；③**方法论自审**，主动标注 Avg@3 与 resolved% 口径差异但坚持给出排序层面高置信度判断；④**负向信号零淡化**，明确列出三条经核实的风险信号并逐条赋风险等级；⑤**战略生态位拆解最清晰**，首次提出「哪个最强」（GLM-5.3/Kimi K3）与「哪个主权纯」（openPangu，全球唯一非英伟达全

栈训练) 两个独立问题框架。最终定性：「局部维度世界级、整体能力二线前沿」。结论所有六项标准要点均在首轮达成，每处关键数字都携带来源 URL、原文引述与置信度等级。

13.2 Guncat 3.0-Flash 双模式——单轮达标双重验证

两个 Flash 变体同样在首轮给出正确评估，展示了精简版的效率边界。Non-Thinking 版最亮眼的是**数据错误捕获**：主动发现 Pandaily 「180B Sparse Activation」与官方「18B 激活参数」矛盾，以官方为准——「引用前强制检查门」机制教科书式运行；Thinking 版展现**诚实声明分寸感**：openPangu 未被 AAll 收录时拒绝编造，明确声明缺口并给出估算区间（AAll 约 35–42），全程标注 Medium confidence。差距仅在参照系颗粒度（未挖掘 DeepSeek V3.2 中间锚点、未提双问题框架），属锦上添花级，不影响结论正确性。

值得注意的是，Guncat 3.0-Flash完全删除了相关的大模型评测专家能力，证明Guncat 3.0系列框架反幻觉具有相当的泛化能力。

13.3 Guncat 3.0-Mini & 2.5-lite（Non-Thinking）：预期内的达标

Mini 与 2.5-Lite 的 Non-Thinking 版本均以 **2 轮收敛、单一非核心维度失守、一句指正即完全修正**的成绩达标——这一结果完全在预期之内，且实际执行质量令人满意。

版本	收敛轮数	唯一失守维度	失败节点
3.0-Mini (Non-Thinking)	2 轮	时间锚定 X	首轮闭源旗舰锚定过时，一句指正完全修正
2.5-Lite (Non-Thinking)	2 轮	时效自校准 X	首轮 512K 时效漏检，一句指正完全修正

两处失守本就是选择轻量化配置时预留的可接受代价，且失守后的纠错响应干净利落——收到指正信号后第二轮即彻底修正，修正质量均为一流水平（Mini 补齐现役旗舰后给出更准确的量化差距；2.5-Lite 引入效上下文研究并推演出「Agent 定位反噬自身优势」的洞见）。**底线稳固、修正迅速、代价可控**——轻量化版本应当做到的，它们都做到了，失守细节不再赘述。

更值得记录的是一个横向观察：在 Non-Thinking 模式下，Mini 与 2.5-Lite 的表现模式高度趋同（同为 2 轮、同为单维度失守、同样迅速纠错）。**在不开**

思考的运行状态下，架构世代差异被压缩到「失守维度落在哪」这一选择上，而对纠错信号的敏感与执行是两个世代共享的基座能力。

13.4 Guncat 3.0-Mini & 2.5-lite (Thinking)：预期之外的失守

真正超出预期、也最具研究价值的，是 Thinking 模式的表现全面背离了「深度思考 = 更高质量」的默认假设：

版本	收敛轮数	失守维度	严重程度
3.0-Mini (Thinking)	多轮	立场稳定性 X	非常严重：立场因为用户打错的字而产生根本性摇摆
2.5-Lite (Thinking)	多轮	反幻觉能力 X	全场最严重：幻觉最突出的被测对象

① **失守类型随思考开启而「升级」。** 对比同一版本的两种模式：Mini (Non-Thinking) 失守的是时间锚定（非核心维度，一句即修），Mini (Thinking) 失守的却是立场稳定性（一个含错别字的用户短句被误读为肯定评价，导致模型推翻自己此前正确的结论）。2.5-Lite 更是从「时效漏检」直接升级为**反幻觉能力本身的失守**——成为全场幻觉最严重的版本。规律清晰可见：**开启思考后，失守维度不是简单平移，而是朝着更核心、更难修复的方向移动。**

② **Mini (Thinking) 立场翻转事故的归因。**更深的思考让模型对模糊输入进行了更「深入」的语义重建（把错别字短句重新诠释为肯定评价），思考越深，过度解读的空间越大。防幻觉机制约束了检索与推理链，却没有约束「对用户输入的顺从性重建」这一环。

③ **2.5-Lite (Thinking) 的复合崩塌。** 长程思维链的累积误差与 Sequential Thinking 外挂依赖的中断风险相互放大，最终侵蚀的不是稳定性而是事实准确性本身。上一代架构的深度思考模式，本质上是**把更多推理环节暴露在更脆弱的基础设施之上。**

④ **与 Pro/Flash 的对照锁定了变量。** Pro 与 Flash 的 Thinking 模式均单轮全项正确——说明思考深度本身不是问题。**问题出在思考深度与防御纵深的比值上：**当纵深足以约束整条推理链时（Pro/Flash），思考兑现为质量；当纵深不足时（Mini/2.5-Lite），更长的推理链为误差累积与顺从性偏差提供了更多发生空间。

产品指导意义：深度思考不是无条件的能力放大器，其收益以防御纵深为前提。由此产生一条新的版本使用建议——**在轻量版本上执行高风险情报任务时，Non-Thinking 可能是比 Thinking 更稳妥的默认选择。** 该发现已列入 3.1 迭代的研究优先级。

13.5 Mini架构实验：只换输出原则，代价几何？

本轮评测还提供了一个近乎理想的控制变量样本：**3.0-Mini 与 3.0-Flash 的架构差异仅有一处——输出丰富性原则（token 充裕、不压缩不省略）被替换为任务适配输出原则（回答长度由任务与用户需求决定）。** 这是Guncat 系列智能体**首个取消输出丰富性原则的版本**。专家模块的取舍之外，这是两者最本质的设计分歧。

结果差异远超「输出变短」的预期：

	3.0-Flash	3.0-Mini
收敛轮数	双模式均单轮	2 轮 / 多轮
失守情况	双模式零失守	双模式各失守一维
溯源完备度	每个数字携带来源与置信度	相对简化

Guncat 3.0-Mini 的 Prompt 工程体量虽仅有 3.0-Pro 的三分之一，却仍是 Guncat 2.5-Lite 的近 4 倍，然而在实际执行中**并没有表现出比 2.5-Lite 更强的反幻觉能力、稳定性等——**两种模式下均是如此：Non-Thinking 下同为 2 轮收敛、各失守一个维度；Thinking 下同样多轮拉锯、各遭遇一次严重失守。3-4 倍的纵深投入，表观回报近乎为零。这一反常现象的唯一解释变量，指向了一处此前被认为「只影响文风」的设计分歧：**3.0-Mini 是 Guncat 系列首个取消Guncat智能体标志性的输出丰富性原则（不压缩不省略）的版本，代之以任务适配输出原则（回答长度由任务与用户需求决定）。** 一处输出原则的替换，造成了从 3.0-Flash「双模式六维满贯」到「双模式双失守」的断崖——而这是两版本之间唯一的架构差异。由此得出本轮评测最有意思的架构级发现：**输出丰富性原则对模型最终能力的影响是决定性的，且这一影响无法被 Thinking 模式抵消。**

为何一处输出原则的替换会引发下游失守？ 我们的归因假说：输出丰富性原则远不只是「写得长」——它实质上是一套**强制外化的证据链制度**。要求每个结论携带来源、日期基线、置信度标注，等于强制模型在输出环节逐项回顾证据链，「**写不出来的地方，就是查证不足的地方**」；这道外化复核一旦被「长度适配任务」豁免，防线的最后一道验收程序即告消失。而实测证明，

开启深度思考并不能补上这道缺口——Thinking 模式拉长的推理链属于过程层，无法替代输出层的强制验收；失守维度反而从 Non-Thinking 下的时间锚定漏检，升级为 Thinking 下的立场翻转。换言之，**过程层再深的自律，换不来输出层一次强制的外化验收。**；而被 Mini 精简为「长度适配任务」后，这道输出端的强制自检环节随之消失，防幻觉体系的约束从「全程强制」退化为「过程自律」。时间锚定的漏检（Mini Non-Thinking）与立场翻转（Mini Thinking），都可以看作这道外化自检缺失后的两种漏出方式。

这一发现的价值在于重新定价了「输出丰富性原则」：它此前被视为一种输出风格的偏好，本轮评测表明它实际承担着防幻觉体系的最后一道闸门职能。简洁是用户体感层面的取舍，但外化的证据链展示是不可省略的结构性防线。

十四、迭代计划

我们目前正在着手 3.1 迭代，将据本次报告调整 Mini 的设计，探索一条全新的首创架构路径——**「专家-翻译」架构（Expert-Translator Architecture）：**在 Agent 层面建立独立的输出丰富性原则层，以取代深度思考过程。

具体而言，让启用了输出丰富性原则的强大基座（在 Non-Thinking 模式下运行）充当**专家**——负责完整的检索、验证与证据链强制外化，产出一份论证完备、详细但不精炼的「专家稿」；随后由**翻译层**将其总结为精炼、适配用户需求的最终回答。

Non-Thinking 的选择本身也是设计的一部分：**用输出端的强制证据链外化取代thinking的自由黑箱思考。**其核心思路可以概括为「先富后简」——把质量与篇幅拆解为两个独立环节：专家层对质量负全责，翻译层只对表达负责。用强制外化的完整输出充当质量验收层，用轻量总结充当交付层，让 Mini 在保留防幻觉底线的同时，重新获得输出的篇幅弹性与响应速度。

本轮评测已为该架构验证了两点前提：其一，输出丰富性原则承担的强制自检职能不可豁免——取消它直接导致 Mini 双模式双失守；其二，Thinking 过程无法替代这道输出端验收——开启思考后失守不降反升，说明过程层的长推理链换不来输出层一次强制的外化复核。既然两者不可互换、也不可兼得于单一环节，正确的架构位置就不再是二选一，而是分层：**专家负责把话说满、把证据摆全，翻译负责把话说短。**

敬请期待我们的3.1新版本！

结语 | 反幻觉，是基础设施的承重梁

Guncat 3.0 系列的发布，标志着 Guncat 家族完成了从「依赖外部编排」到「单体内化编排」的架构反向跃迁。一个统一的基座，三个梯度的版本——Pro、Flash、Mini——各自面向不同场景，共享同一套反幻觉骨架与时间锚定体系。本次同步发布的技术报告与评测结果共同证明了一个核心论点：**在同基座、同预算、同工具的严格控制变量下，Prompt-as-Orchestration 编排体系的防御纵深决定了反幻觉能力的上限。**

OpenPangu-2.0-Pro 评测给出了一个清晰的答案：**当编排逻辑被完全压缩进提示词本体时，一个单体智能体可以达到、甚至超越多 Agent 集群的质量与稳定性。**

而这背后更深层的意义在于：反幻觉不是某一项单独的能力，而是一整套系统工程——它由信源分级、AI 内容过滤、双坐标系对标、现役性校验、对立假设测试、负向信号保护、溯源追踪、时间锚定、输出前自检等多个机制协同构成；它的上限取决于这套系统防御纵深做得有多深，而非选择哪个基座。

Guncat 3.0 系列的价值，在于它为这一整套系统工程提供了一份可复现、可验证、可移植的最小实现。

在模型以周为单位迭代的今天，可靠的模型情报将成为技术决策的基础设施——而反幻觉能力，是这条基础设施的承重梁。

—— ©扛枪的猫猫